Scaling Limits of the Dropout Inversion Attack: An Empirical Analysis Under Increasing Input Dimensionality

Eduardo Gordiano Passos Silva [1] Rodrigo Cesar Pedrosa Silva [1]

[1]Universidade Federal de Ouro Preto (UFOP) — Laboratório de Computação de Sistemas Inteligentes (CSI Lab)

Abstract

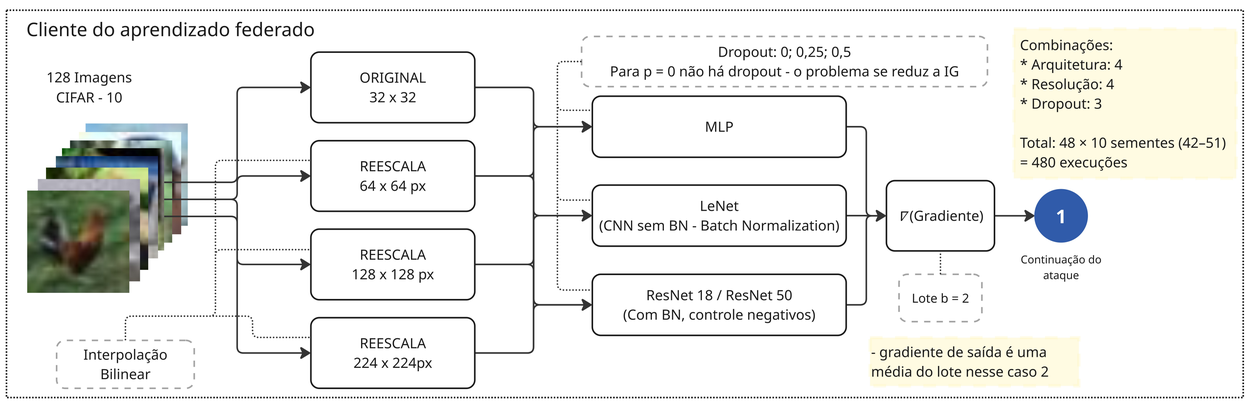
Gradient inversion attacks reconstruct private training samples from shared gradients in federated learning. The Dropout Inversion Attack (DIA) bypasses dropout-based defenses by jointly optimizing the synthetic input and the attacker's dropout masks. We characterize DIA's scalability via a factorial experiment on CIFAR-10 upscaled from 32×32 to 224×224 pixels, across four architectures and three dropout rates. For the MLP, reconstruction quality decreases monotonically with resolution while wall-clock time grows superlinearly; LeNet maintains high quality throughout; ResNets fail entirely, an effect attributed to batch normalization. DIA scalability is architecture-dependent: for MLP-type models, the practical barrier at scale is computational rather than qualitative.

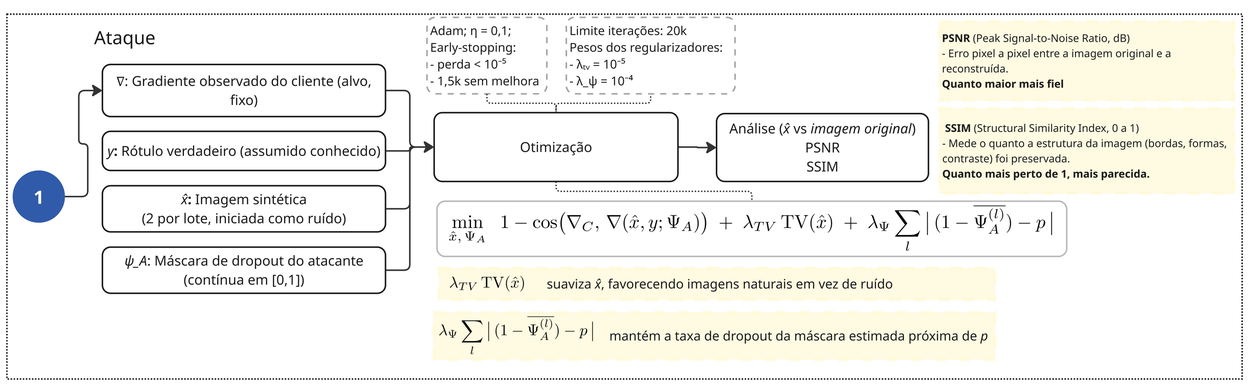
Introdução, Objetivos e Hipóteses

FL evita dados brutos: clientes só transmitem gradientes [4]. Mas *ataques de inversão de gradiente* reconstroem os dados originais a partir deles [2,3]. *Dropout* [5] é tratado como defesa, pois parece degradar esses ataques — mas Scheliga et al. [1] mostraram que a proteção é *ilusória*: a degradação vem do *desalinhamento* entre a máscara do cliente (Ψ_C) e a do atacante (Ψ_A). O **DIA** supera isso otimizando $\hat{x}$ e Ψ_A (y é conhecido; detalhes na Metodologia) — mas os experimentos originais ficaram em **baixa resolução**, deixando em aberto o comportamento em alta resolução ($X = C{\cdot}H{\cdot}W$ grande).

- **Objetivo:** investigar a **fronteira de viabilidade** do DIA em função da escala de entrada (experimento fatorial, ver Metodologia)
- **H1 (escala ⇒ qualidade e custo):** para o MLP com $p = 0$, a qualidade de reconstrução (PSNR/SSIM) decresce monotonicamente com a resolução, e o custo (iterações, tempo de parede) cresce de forma supralinear.
- **H2 (interação dropout × resolução):** para $p > 0$, o comportamento do DIA não coincide com o de $p = 0$, sobretudo em resoluções intermediárias e altas.

Metodologia





Ambiente: Ryzen 9 7900X, 16 GB RAM, GPU RTX 5060 Ti 8 GB (`cuda:0`), PyTorch 2.11, Python 3.14.

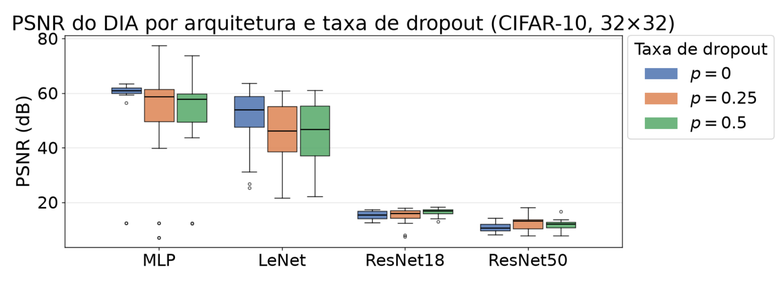
Resultados: Efeito da Resolução no MLP

PSNR (dB) do DIA no MLP por resolução e taxa de dropout. Média ± desvio.

Resolução	$p = 0{,}0$	$p = 0{,}25$	$p = 0{,}5$
32×32	56,09 ± 15,00	49,36 ± 21,57	52,73 ± 15,40
64×64	42,15 ± 14,60	40,19 ± 16,92	32,57 ± 15,39
128×128	28,09 ± 9,77	29,97 ± 7,39	19,19 ± 10,58
224×224	27,23 ± 6,33	27,37 ± 7,54	27,85 ± 8,35

- Ataque viável em **todas** as taxas de dropout a 224×224 (PSNR 27–28 dB) — muito acima do piso de ruído das ResNets (9–16 dB); dropout é *ilusório* mesmo sob $p = 0{,}5$
- Monotonicidade com a resolução só em $p = 0$ e $p = 0{,}25$ (apoia H1)
- $p = 0{,}5$: queda abrupta a 128×128, recuperação a 224×224 (compatível com H2)
- Custo cresce **supralinear** com a resolução, em qualquer p (detalhado adiante)

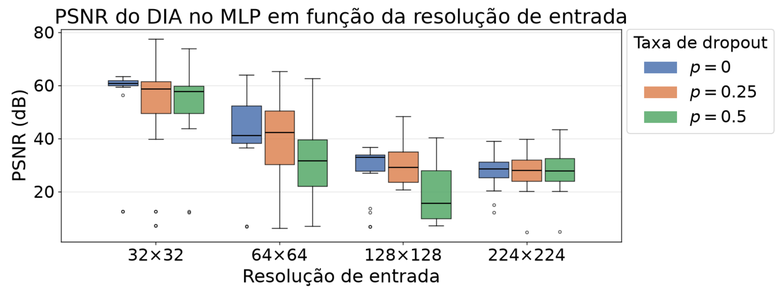
A Penalidade de Escala Depende da Arquitetura



Caixas mostram mediana, quartis (Q_1–Q_3) e amplitude dentro de 1,5 IQR; pontos são *outliers* (baseline 32×32).

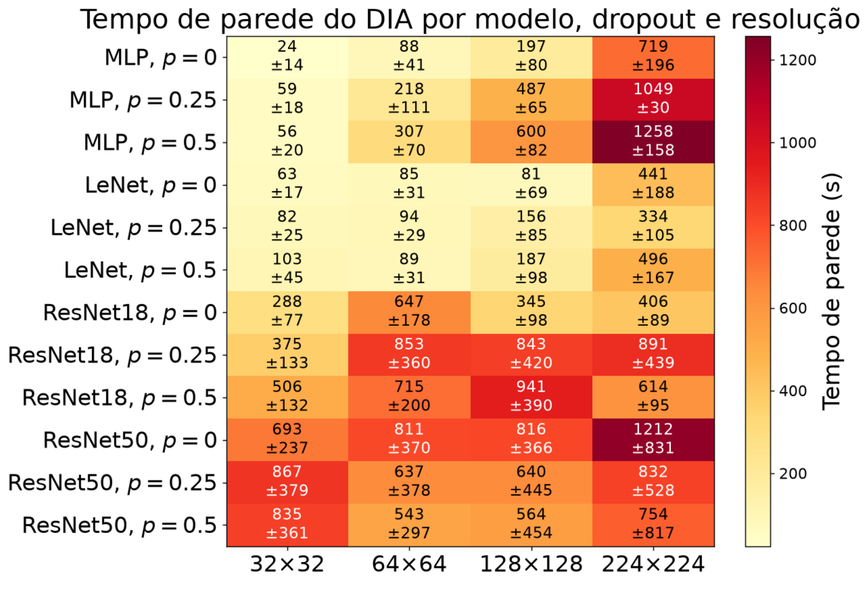
- LeNet (CNN sem BN): PSNR entre 32–52 dB de 32 a 224 px, *sem* tendência monotônica — pesos convolucionais preservam a relação sinal/gradiente
- ResNets falham em **todas** as resoluções/taxas (PSNR 9,6–16,5 dB a 32×32) — efeito do *batch normalization*, não da escala da entrada

Interação entre Dropout e Resolução



- Distribuição completa por trás da tabela anterior: a dispersão (IQR) muda de padrão por condição
- 32×32/64×64: p=0,25 mais varia (IQR ≈ 12–20 dB)
- 128×128: p=0,5 dispara (IQR 18,1 dB, quase o dobro) — coincide com a queda abrupta de PSNR médio
- Outliers de baixo PSNR em quase todas as condições: uma fração pequena das amostras resiste mais, independente da resolução

Custo Computacional por Modelo, Dropout e Resolução



Média ± desvio sobre 10 execuções (sementes 42–51), GPU RTX 5060 Ti.

- A 224×224, tempo de parede do MLP: 719 ± 196 s ($p = 0$) → 1 049 ± 30 s (p=0,25) → 1 258 ± 158 s (p=0,5)
- Apoia H2 parcialmente, sobretudo na dimensão custo

Conclusões

- MLP: barreira em escala é **computacional**, não qualitativa (SSIM mantido em 0,756–0,877).
- Penalidade de escala **depende da arquitetura**: LeNet resiste, ResNets falham por BN (não pela escala).
- Dropout sempre eleva o custo, mas **nunca** impede o ataque — defesa ilusória em qualquer p.
- **Trabalhos futuros:** imagens nativas de alta resolução; ResNet sem BN; resoluções > 224 px; dropout + compressão de gradiente.

Referências

[1] Scheliga, Mäder, Seeland. Dropout Is NOT All You Need to Prevent Gradient Leakage. *AAAI*, 2023. [2] Geiping et al. Inverting Gradients – How easy is it to break privacy in federated learning? *NeurIPS*, 2021. [3] Zhu, Liu, Han. Deep Leakage from Gradients. *NeurIPS*, 2019. [4] McMahan et al. Communication-Efficient Learning of Deep Networks from Decentralized Data. *AISTATS*, 2017. [5] Srivastava et al. Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *JMLR*, 2014.